

Statistiques - Correction du TD de pré-rentree

2026-09-22

Contents

1	Statistiques - Correction du TD de pré-rentree	1
1.1	Sommaire	2
1.2	Exercice 1 - Fréquences empiriques et données catégorielles	2
1.2.1	1. Interpréter $\hat{p}_k$ et montrer que $\hat{p}$ est un vecteur de probabilités	2
1.2.2	2. Espérance, variance et covariance des fréquences	3
1.2.3	3. Convergence vers les vraies probabilités	4
1.3	Exercice 2 - Divergence de Bregman, KL et entropie croisée	5
1.3.1	1. Cas de la norme euclidienne au carré	6
1.3.2	2. La divergence KL comme divergence de Bregman	7
1.3.3	3. Positivité de la divergence KL	9
1.3.4	4. Excès d'objectif et divergence de Bregman	9
1.3.5	5. Entropie croisée et meilleur classifieur probabiliste	10
1.4	Exercice 3 - ACP	10
1.4.1	1. Première direction principale	10
1.4.2	2. Les k premières directions	11
1.4.3	3. Part de variance expliquée	11
1.4.4	4. L'ACP comme meilleure approximation linéaire	11
1.4.5	5. Lien avec la SVD	12
1.5	Exercice 4 - Méthode des moments et maximum de vraisemblance	12
1.5.1	1. Estimateur des moments	12
1.5.2	2. Estimateur du maximum de vraisemblance	13
1.5.3	3. Loi, biais et variance de l'estimateur du maximum	13
1.5.4	4. Biais, variance et comparaison des risques quadratiques	14
1.5.5	5. Corriger le biais du maximum	14
1.5.6	6. Comportement asymptotique non standard	15
1.6	Exercice 5 - Estimateurs du maximum de vraisemblance	15
1.6.1	1(a). MLE du paramètre de Bernoulli	15
1.6.2	1(b). Information de Fisher	16
1.6.3	1(c). Loi asymptotique et borne de Cramér-Rao	16

1 Statistiques - Correction du TD de pré-rentree

Cours associé : cours-principal.

Abstract — Périmètre de la note Cette note reprend seulement les exercices qui comportent une correction manuscrite dans le TD annoté : les exercices 1 à 4, puis les questions 1(a), 1(b) et 1(c) de l'exercice 5. Les questions sans trace de correction manuscrite sont volontairement laissées de côté.

1.1 Sommaire

- 1. Fréquences empiriques
 - 2. Divergence de Bregman et KL
 - 3. ACP
 - 4. Moments contre vraisemblance
 - 5. Estimateur de Bernoulli
-

1.2 Exercice 1 - Fréquences empiriques et données catégorielles

On observe $X_1, \dots, X_n$ i.i.d. à valeurs dans $\{1, \dots, K\}$, avec $\mathbb{P}(X_i = k) = p_k$. Pour chaque observation,

$$Z_i = (\mathbf{1}_{\{X_i=1\}}, \dots, \mathbf{1}_{\{X_i=K\}})^\top, \quad \hat{p} = \frac{1}{n} \sum_{i=1}^n Z_i.$$

1.2.1 1. Interpréter $\hat{p}_k$ et montrer que $\hat{p}$ est un vecteur de probabilités

Question — Question Interpréter $\hat{p}_k$. Montrer que $\hat{p}$ est un vecteur de probabilités.

La coordonnée k vaut

$$\hat{p}_k = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i=k\}}.$$

Chaque indicatrice vaut 1 quand l'observation est dans la catégorie k , et 0 sinon. Leur somme compte donc les observations de catégorie k ; après division par n , $\hat{p}_k$ est leur **proportion observée**.

Toutes les coordonnées sont positives ou nulles. De plus,

$$\sum_{k=1}^K \hat{p}_k = \frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K \mathbf{1}_{\{X_i=k\}}$$

Regardons la somme intérieure pour une observation fixée X_i . Puisque X_i prend une unique valeur dans $\{1, \dots, K\}$, il existe une unique catégorie, notée k_i , telle que $X_i = k_i$. On a donc

$$\mathbf{1}_{\{X_i=1\}} + \dots + \mathbf{1}_{\{X_i=k_i\}} + \dots + \mathbf{1}_{\{X_i=K\}} = 0 + \dots + 1 + \dots + 0 = 1.$$

Autrement dit,

$$\sum_{k=1}^K \mathbf{1}_{\{X_i=k\}} = 1.$$

Cette égalité est vraie séparément pour chaque i . On peut donc la remplacer dans la somme extérieure :

$$\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K \mathbf{1}_{\{X_i=k\}} = \frac{1}{n} \sum_{i=1}^n 1 = 1.$$

Ainsi $\hat{p}$ est bien un vecteur de probabilités.

1.2.2 2. Espérance, variance et covariance des fréquences

Question — Question Calculer $\mathbb{E}[\hat{p}_k]$, $\text{Var}(\hat{p}_k)$ et, si $k \neq \ell$, $\text{Cov}(\hat{p}_k, \hat{p}_\ell)$. Interpréter le signe de cette covariance.

Le nombre d'observations dans la catégorie k est

$$n\hat{p}_k = \sum_{i=1}^n \mathbf{1}_{\{X_i=k\}} \sim \text{Bin}(n, p_k).$$

Pour une loi binomiale $B \sim \text{Bin}(n, p_k)$, on connaît les deux moments

$$\mathbb{E}[B] = np_k, \quad \text{Var}(B) = np_k(1 - p_k).$$

Or $\hat{p}_k = B/n$. Diviser une variable aléatoire par n divise son espérance par n et sa variance par n^2 . Donc

$$\begin{aligned} \mathbb{E}[\hat{p}_k] &= \mathbb{E}\left[\frac{B}{n}\right] = \frac{1}{n}\mathbb{E}[B] = \frac{1}{n}(np_k) = p_k, \\ \text{Var}(\hat{p}_k) &= \text{Var}\left(\frac{B}{n}\right) = \frac{1}{n^2}\text{Var}(B) = \frac{1}{n^2}np_k(1 - p_k) = \frac{p_k(1 - p_k)}{n}. \end{aligned}$$

Pour $k \neq \ell$, une même observation ne peut pas être à la fois dans les catégories k et ℓ . Ainsi,

$$\mathbf{1}_{\{X_i=k\}} \mathbf{1}_{\{X_i=\ell\}} = 0.$$

En appliquant la définition de la covariance,

$$\begin{aligned} \text{Cov}(\mathbf{1}_{\{X_i=k\}}, \mathbf{1}_{\{X_i=\ell\}}) &= \mathbb{E}[\mathbf{1}_{\{X_i=k\}} \mathbf{1}_{\{X_i=\ell\}}] - \mathbb{E}[\mathbf{1}_{\{X_i=k\}}] \mathbb{E}[\mathbf{1}_{\{X_i=\ell\}}] \\ &= 0 - p_k p_\ell \\ &= -p_k p_\ell. \end{aligned}$$

Pour passer des indicatrices aux fréquences, repartons de leurs définitions :

$$\hat{p}_k = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i=k\}}, \quad \hat{p}_\ell = \frac{1}{n} \sum_{j=1}^n \mathbf{1}_{\{X_j=\ell\}}.$$

On utilise deux propriétés générales de la covariance : les constantes se mettent en facteur, et la covariance est linéaire dans chacune de ses deux entrées. Pour des variables A_i et B_j ,

$$\text{Cov}\left(\sum_i A_i, \sum_j B_j\right) = \sum_i \sum_j \text{Cov}(A_i, B_j).$$

Cette dernière égalité vient directement de la définition $\text{Cov}(A, B) = \mathbb{E}[AB] - \mathbb{E}[A]\mathbb{E}[B]$ et de la linéarité de l'espérance. En remplaçant A_i et B_j par les indicatrices ci-dessus, on obtient donc

$$\begin{aligned}\text{Cov}(\hat{p}_k, \hat{p}_\ell) &= \text{Cov}\left(\frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i=k\}}, \frac{1}{n} \sum_{j=1}^n \mathbf{1}_{\{X_j=\ell\}}\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \text{Cov}(\mathbf{1}_{\{X_i=k\}}, \mathbf{1}_{\{X_j=\ell\}}).\end{aligned}$$

Si $i \neq j$, les deux indicatrices concernent deux observations indépendantes, donc leur covariance est nulle. Il ne reste que les n termes diagonaux $i = j$, tous égaux à $-p_k p_\ell$. Ainsi,

$$\begin{aligned}\text{Cov}(\hat{p}_k, \hat{p}_\ell) &= \frac{1}{n^2} \sum_{i=1}^n (-p_k p_\ell) \\ &= \boxed{-\frac{p_k p_\ell}{n}}.\end{aligned}$$

Intuition — La covariance est négative parce que les fréquences doivent se partager une masse totale égale à 1. Si une catégorie est surreprésentée dans l'échantillon, les autres ont tendance à être sous-représentées.

1.2.3 3. Convergence vers les vraies probabilités

Question — Question Montrer que $\hat{p}$ converge presque sûrement vers $p = (p_1, \dots, p_K)^\top$.

Fixons une catégorie k et posons

$$I_i^{(k)} = \mathbf{1}_{\{X_i=k\}}.$$

Cette variable ne retient de X_i qu'une information : « l'observation est-elle dans la catégorie k ? ». Elle suit une loi de Bernoulli :

$$\mathbb{P}(I_i^{(k)} = 1) = \mathbb{P}(X_i = k) = p_k, \quad \mathbb{P}(I_i^{(k)} = 0) = 1 - p_k.$$

Les X_i sont i.i.d. et l'on leur applique tous la même fonction, $x \mapsto \mathbf{1}_{\{x=k\}}$. Les $I_i^{(k)}$ sont donc elles aussi i.i.d. Elles sont intégrables car elles ne prennent que les valeurs 0 et 1. Enfin,

$$\mathbb{E}[I_i^{(k)}] = 1 \times p_k + 0 \times (1 - p_k) = p_k.$$

Theorem — Rappel — loi forte des grands nombres Si $Y_1, Y_2, \dots$ sont des variables i.i.d. telles que $\mathbb{E}[|Y_1|] < +\infty$, alors

$$\frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow[n \rightarrow \infty]{\text{p.s.}} \mathbb{E}[Y_1].$$

La moyenne empirique converge donc presque sûrement vers l'espérance de la variable observée.

On peut appliquer ce résultat aux $I_i^{(k)}$, car elles sont i.i.d. et bornées, donc intégrables :

$$\hat{p}_k = \frac{1}{n} \sum_{i=1}^n I_i^{(k)} \xrightarrow[n \rightarrow \infty]{\text{p.s.}} p_k.$$

La notation « presque sûrement » signifie qu'avec probabilité 1, une fois que l'on a tiré une suite infinie d'observations, sa fréquence empirique $\hat{p}_k$ se rapproche de p_k et y reste aussi proche que l'on veut à partir d'un certain rang.

Cela est vrai pour chacune des K coordonnées. Comme il y en a un nombre fini,

$$\hat{p} \xrightarrow[n \rightarrow \infty]{\text{p.s.}} p.$$

Autrement dit, avec beaucoup de données, les proportions observées finissent presque sûrement par révéler les proportions de la population.

1.3 Exercice 2 - Divergence de Bregman, KL et entropie croisée

Pour une fonction F différentiable et strictement convexe,

$$D_F(p, q) = F(p) - F(q) - \langle \nabla F(q), p - q \rangle.$$

Intuition — $D_F(p, q)$ mesure l'écart entre la vraie valeur de F en p et ce qu'aurait prédit l'approximation linéaire de F construite autour de q .

Exemple — Commencer par une fonction d'une variable Si $F : \mathbb{R} \rightarrow \mathbb{R}$, on peut dessiner sa courbe. Le point de la courbe d'abscisse q est $(q, F(q))$. La **droite tangente en q** est la droite qui passe par ce point et qui a la même pente que la courbe à cet endroit. Cette pente est $F'(q)$, et l'équation de la droite est

$$T_q(x) = F(q) + F'(q)(x - q).$$

Ainsi, $F(q)$ n'est pas une « hauteur » au sens physique : c'est simplement la valeur de sortie de la fonction au point q . C'est l'ordonnée du point de contact et, par conséquent, la valeur de départ de la droite tangente.

Quand F dépend de plusieurs variables, on ne peut plus représenter son graphe par une courbe dans un plan. La droite tangente devient alors un **plan tangent** : c'est la généralisation de cette droite, qui passe toujours par le point $(q, F(q))$ et possède les mêmes pentes locales que F en q .

On note cette approximation affine T_q . Son évaluation en un point quelconque x est

$$T_q(x) = F(q) + \langle \nabla F(q), x - q \rangle.$$

Ici, le gradient $\nabla F(q)$ joue le rôle de la pente $F'(q)$: il rassemble les pentes selon toutes les directions. En particulier, à la position p , cette approximation prédit

$$T_q(p) = F(q) + \langle \nabla F(q), p - q \rangle.$$

La divergence de Bregman est alors simplement

$$\begin{aligned} D_F(p, q) &= F(p) - [F(q) + \langle \nabla F(q), p - q \rangle] \\ &= F(p) - T_q(p). \end{aligned}$$

Les éléments de la formule ont donc les rôles suivants :

- $F(p)$ est la vraie valeur de la fonction au point que l'on veut atteindre ;
- $F(q)$ est la vraie valeur de la fonction au point de départ q ; la tangente ou le plan tangent passe donc par $(q, F(q))$;
- $p - q$ est le déplacement de q vers p ;
- $\langle \nabla F(q), p - q \rangle$ est la variation que prédit la pente locale de F le long de ce déplacement.

En dimension 1, le produit scalaire devient un produit ordinaire et l'on retrouve exactement la formule de la droite tangente :

$$F(p) \approx F(q) + F'(q)(p - q).$$

Pour une fonction convexe, le plan tangent est toujours sous le graphe :

$$F(p) \geq T_q(p).$$

Ainsi $D_F(p, q) \geq 0$. L'ordre des arguments compte : on évalue la tangente construite en q au point p , ce qui explique pourquoi, en général, $D_F(p, q)$ et $D_F(q, p)$ ne coïncident pas.

1.3.1 1. Cas de la norme euclidienne au carré

Question — Question Montrer que, pour $F(x) = \|x\|_2^2$, on a $D_F(p, q) = \|p - q\|_2^2$.

Ici $\nabla F(x) = 2x$. En remplaçant dans la définition,

$$\begin{aligned} D_F(p, q) &= \|p\|_2^2 - \|q\|_2^2 - \langle 2q, p - q \rangle \\ &= \|p\|_2^2 - \|q\|_2^2 - 2\langle q, p - q \rangle \\ &= \|p\|_2^2 - \|q\|_2^2 - 2(\langle q, p \rangle - \langle q, q \rangle) \\ &= \|p\|_2^2 - \|q\|_2^2 - 2\langle p, q \rangle + 2\|q\|_2^2 \\ &= \|p\|_2^2 + \|q\|_2^2 - 2\langle p, q \rangle \\ &= \|p - q\|_2^2. \end{aligned}$$

Cette identité explique le mot « généralise » : en choisissant la fonction particulière $F(x) = \|x\|_2^2$, la divergence de Bregman retrouve exactement le carré de l'écart euclidien. Avec une autre fonction convexe F , on remplace cette mesure quadratique de l'écart par l'écart entre F et sa tangente ; la manière de mesurer la différence entre p et q s'adapte alors à la géométrie de F .

Exemple — Un exemple à un seul nombre Prenons $F(x) = x^2$, $q = 1$ et $p = 3$. La tangente construite en $q = 1$ est

$$T_1(x) = F(1) + F'(1)(x - 1) = 1 + 2(x - 1) = 2x - 1.$$

Au point $p = 3$, la vraie courbe vaut $F(3) = 9$, tandis que sa tangente prédit seulement $T_1(3) = 5$. L'écart entre les deux est donc

$$D_F(3, 1) = 9 - 5 = 4 = (3 - 1)^2.$$

Dans ce cas précis, la règle de Bregman donne exactement le carré de la distance euclidienne. « Généraliser » signifie ici : garder une recette qui fonctionne pour cette distance particulière, tout en autorisant d'autres choix de fonction F pour définir d'autres écarts.

Une divergence de Bregman conserve deux propriétés utiles de l'écart quadratique :

$$D_F(p, q) \geq 0, \quad D_F(q, q) = 0.$$

Lorsque F est strictement convexe, $D_F(p, q) = 0$ implique même $p = q$. En revanche, elle n'est généralement pas une distance au sens mathématique :

- elle peut être non symétrique, avec $D_F(p, q) \neq D_F(q, p)$;
- elle ne vérifie pas nécessairement l'inégalité triangulaire.

Note — Même $\|p - q\|_2^2$ n'est pas une distance au sens strict : c'est son carré qui intervient ici, et le carré ne satisfait pas en général l'inégalité triangulaire. La distance euclidienne elle-même est $\|p - q\|_2$.

La divergence de Bregman est donc plutôt une **mesure directionnelle d'écart** : elle compare p à l'approximation de F construite autour de q .

1.3.2 2. La divergence KL comme divergence de Bregman

Question — Question Pour $H(p) = -\sum_{i=1}^K p_i \log p_i$ et $\text{KL}(p, q) = \sum_{i=1}^K p_i \log(p_i/q_i)$, montrer que KL est la divergence de Bregman associée à $-H$.

L'entropie d'un vecteur de probabilités $r = (r_1, \dots, r_K)$ est définie par

$$H(r) = -\sum_{i=1}^K r_i \log r_i.$$

Pour construire une divergence de Bregman, on veut utiliser une fonction convexe. Or c'est $-H$, et non H , qui est convexe. On choisit donc

$$F = -H.$$

Pour le vérifier, regardons un terme de l'entropie, défini pour $x > 0$ par

$$h(x) = -x \log x.$$

Ses dérivées sont

$$\begin{aligned} h'(x) &= -\frac{d}{dx}(x \log x) \\ &= -\left(1 \times \log x + x \times \frac{1}{x}\right) \\ &= -(1 + \log x). \\ h''(x) &= -\frac{1}{x} < 0. \end{aligned}$$

La deuxième égalité utilise la règle du produit : la dérivée de x est 1, et celle de $\log x$ est $1/x$.

Une dérivée seconde strictement négative signifie que la courbe est tournée vers le bas : h est strictement concave. Comme

$$H(r) = \sum_{i=1}^K h(r_i),$$

l'entropie H est elle aussi strictement concave sur l'intérieur du simplexe. Elle n'est donc pas convexe, sauf dans le cas dégénéré où l'on se limiterait à un seul point. Changer le signe retourne la courbure : $-H$ est strictement convexe, ce qui est précisément la propriété requise pour définir une divergence de Bregman.

Le signe moins de $F = -H$ annule celui qui apparaît dans la définition de H :

$$\begin{aligned} F(r) &= -H(r) \\ &= - \left(- \sum_{i=1}^K r_i \log r_i \right) \\ &= \sum_{i=1}^K r_i \log r_i. \end{aligned}$$

La formule est valable pour tout vecteur de probabilités r dont les coordonnées sont strictement positives. Dans la définition de $D_F(p, q)$, il faut notamment calculer $F(q)$; on remplace donc simplement r par q :

$$F(q) = \sum_{i=1}^K q_i \log q_i.$$

Sa i -ème dérivée est $1 + \log q_i$. On développe alors :

$$\begin{aligned} D_{-H}(p, q) &= \sum_i p_i \log p_i - \sum_i q_i \log q_i - \sum_i (1 + \log q_i)(p_i - q_i) \\ &= \sum_i p_i \log p_i - \sum_i q_i \log q_i - \sum_i (p_i + p_i \log q_i - q_i - q_i \log q_i) \\ &= \sum_i p_i \log p_i - \sum_i q_i \log q_i - \sum_i p_i - \sum_i p_i \log q_i + \sum_i q_i + \sum_i q_i \log q_i \\ &= \sum_i p_i \log p_i - \sum_i q_i \log q_i - 1 - \sum_i p_i \log q_i + 1 + \sum_i q_i \log q_i \\ &= \sum_i p_i \log p_i - \sum_i p_i \log q_i \\ &= \sum_i p_i \log \left(\frac{p_i}{q_i} \right) \\ &= \text{KL}(p, q). \end{aligned}$$

Les termes linéaires disparaissent parce que $\sum_i p_i = \sum_i q_i = 1$.

1.3.3 3. Positivité de la divergence KL

Question — Question Montrer que $\text{KL}(p, q) \geq 0$, avec égalité si et seulement si $p = q$.

La fonction $-H$ est strictement convexe sur l'intérieur du simplexe. Son graphe est donc toujours au-dessus de sa tangente en q :

$$(-H)(p) \geq (-H)(q) + \langle \nabla(-H)(q), p - q \rangle.$$

Pour isoler l'écart entre les deux membres, on soustrait le membre de droite aux deux côtés :

$$(-H)(p) - [(-H)(q) + \langle \nabla(-H)(q), p - q \rangle] \geq 0.$$

En développant les crochets, le membre de gauche devient

$$(-H)(p) - (-H)(q) - \langle \nabla(-H)(q), p - q \rangle.$$

C'est exactement la définition de la divergence de Bregman associée à la fonction $F = -H$:

$$D_{-H}(p, q) = (-H)(p) - (-H)(q) - \langle \nabla(-H)(q), p - q \rangle.$$

La question précédente a ensuite montré, par calcul direct, que

$$D_{-H}(p, q) = \text{KL}(p, q).$$

La convexité de $-H$ donne donc

$$\text{KL}(p, q) \geq 0.$$

La stricte convexité donne l'égalité uniquement lorsque $p = q$.

Warning — Malgré sa positivité, la divergence KL n'est pas une distance : en général $\text{KL}(p, q) \neq \text{KL}(q, p)$, et l'inégalité triangulaire n'est pas satisfaite.

1.3.4 4. Excès d'objectif et divergence de Bregman

Question — Question Soit w^* un minimiseur de R sur un ouvert convexe. Montrer que $E(w) = R(w) - R(w^*) = D_R(w, w^*)$ et préciser la condition d'optimalité utilisée.

Comme w^* est un minimiseur intérieur d'une fonction différentiable,

$$\nabla R(w^*) = 0.$$

C'est la condition d'optimalité du premier ordre. Elle annule le terme linéaire dans la divergence :

$$\begin{aligned} D_R(w, w^*) &= R(w) - R(w^*) - \langle \nabla R(w^*), w - w^* \rangle \\ &= R(w) - R(w^*) \\ &= E(w). \end{aligned}$$

Ainsi, lorsque l'on compare un point à un minimum intérieur, la divergence de Bregman est exactement l'excès de critère.

1.3.5 5. Entropie croisée et meilleur classifieur probabiliste

Question — Question Pour la perte $\ell(q, Y) = -\log q_Y$, montrer que le risque $R(q) = \mathbb{E}[\ell(q, Y)]$ vaut $H(p) + \text{KL}(p, q)$. En déduire la prédiction optimale dans la population et l'excès de risque.

Si la vraie classe Y suit la loi p , alors

$$R(q) = -\sum_{k=1}^K p_k \log q_k.$$

On ajoute et retranche $\sum_k p_k \log p_k$:

$$\begin{aligned} R(q) &= -\sum_k p_k \log p_k + \sum_k p_k \log \left(\frac{p_k}{q_k} \right) \\ &= H(p) + \text{KL}(p, q). \end{aligned}$$

Le terme $H(p)$ ne dépend pas de la prédiction q . Comme la KL est minimale et nulle lorsque $q = p$, la prédiction optimale est

$$q^* = p.$$

Le risque minimal est $H(p)$ et l'excès de risque est

$$R(q) - R(q^*) = \text{KL}(p, q).$$

Intuition — Avec la cross-entropie, annoncer les vraies probabilités conditionnelles est optimal. La divergence KL mesure exactement le prix payé quand les probabilités annoncées s'en écartent.

1.4 Exercice 3 - ACP

Les observations $x_1, \dots, x_n \in \mathbb{R}^p$ sont centrées. Leur matrice de covariance empirique est

$$\widehat{\Sigma} = \frac{1}{n} \sum_{i=1}^n x_i x_i^\top.$$

On note $\lambda_1 \geq \dots \geq \lambda_p \geq 0$ ses valeurs propres et $v_1, \dots, v_p$ des vecteurs propres orthonormés associés.

1.4.1 1. Première direction principale

Question — Question Montrer que $v_1 \in \arg \max_{\|v\|_2=1} \frac{1}{n} \sum_{i=1}^n (v^\top x_i)^2$.

La variance empirique des données projetées sur une direction unitaire v est

$$\frac{1}{n} \sum_{i=1}^n (v^\top x_i)^2 = v^\top \widehat{\Sigma} v.$$

Écrivons $v = \sum_{j=1}^p a_j v_j$. Comme $\|v\|_2 = 1$, on a $\sum_j a_j^2 = 1$. Alors

$$v^\top \widehat{\Sigma} v = \sum_{j=1}^p \lambda_j a_j^2 \leq \lambda_1 \sum_{j=1}^p a_j^2 = \lambda_1.$$

L'égalité est atteinte avec $v = v_1$. La première direction principale est donc la direction qui conserve la plus grande variance possible après projection sur une droite.

1.4.2 2. Les k premières directions

Question — Question Expliquer comment obtenir les k premières directions principales.

On diagonalise $\widehat{\Sigma}$ et on garde les k vecteurs propres associés aux k plus grandes valeurs propres :

$$v_1, \dots, v_k.$$

Ils sont orthogonaux les uns aux autres. Leur espace engendré,

$$V_k = \text{span}(v_1, \dots, v_k),$$

est le sous-espace de dimension k retenu par l'ACP.

1.4.3 3. Part de variance expliquée

Question — Question Montrer que la fraction de variance expliquée par les k premières composantes est $\frac{\lambda_1 + \dots + \lambda_k}{\lambda_1 + \dots + \lambda_p}$.

La variance totale vaut la trace de la covariance empirique :

$$\text{tr}(\widehat{\Sigma}) = \sum_{j=1}^p \lambda_j.$$

Chaque direction principale v_j explique une quantité de variance égale à λ_j . En gardant les k premières, on conserve donc $\sum_{j=1}^k \lambda_j$ sur un total de $\sum_{j=1}^p \lambda_j$, soit

$$\boxed{\frac{\lambda_1 + \dots + \lambda_k}{\lambda_1 + \dots + \lambda_p}}.$$

1.4.4 4. L'ACP comme meilleure approximation linéaire

Question — Question Montrer que le sous-espace d'ACP de dimension k minimise $\frac{1}{n} \sum_{i=1}^n \|x_i - P_V x_i\|_2^2$ parmi tous les sous-espaces V de dimension k .

Pour tout sous-espace V , le théorème de Pythagore donne

$$\|x_i\|_2^2 = \|P_V x_i\|_2^2 + \|x_i - P_V x_i\|_2^2.$$

Comme le premier membre ne dépend pas de V , minimiser l'erreur de reconstruction revient à maximiser la variance conservée par la projection. Pour un espace de dimension k , cette variance maximale est obtenue en gardant les directions associées aux k plus grandes valeurs propres. Ainsi,

$$V_k = \text{span}(v_1, \dots, v_k)$$

minimise l'erreur quadratique moyenne de reconstruction.

Intuition — L'ACP ne cherche pas des axes « jolis » : elle cherche le plan de dimension k le plus proche du nuage de points au sens des moindres carrés.

1.4.5 5. Lien avec la SVD

Question — Question Si $X = USV^\top$ est une SVD de la matrice de données centrées, relier les directions principales à cette décomposition.

Les lignes de X sont les $x_i^\top$, donc

$$\widehat{\Sigma} = \frac{1}{n} X^\top X.$$

Avec $X = USV^\top$,

$$\widehat{\Sigma} = V \frac{S^\top S}{n} V^\top.$$

Les colonnes de V sont donc les directions principales. Si s_j est la j -ème valeur singulière, la valeur propre correspondante est

$$\lambda_j = \frac{s_j^2}{n}.$$

La SVD permet ainsi de calculer l'ACP directement, même lorsque X n'est pas une matrice carrée.

1.5 Exercice 4 - Méthode des moments et maximum de vraisemblance

On suppose

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{U}([0, \theta]), \quad \theta > 0.$$

On pose $\overline{X}_n = \frac{1}{n} \sum_i X_i$ et $M_n = \max(X_1, \dots, X_n)$.

1.5.1 1. Estimateur des moments

Question — Question Calculer l'estimateur des moments $\hat{\theta}_{\text{MM}}$.

Pour une loi uniforme sur $[0, \theta]$,

$$\mathbb{E}_\theta[X_i] = \frac{\theta}{2}.$$

La méthode des moments remplace l'espérance théorique par la moyenne observée :

$$\overline{X}_n = \frac{\theta}{2}.$$

On résout cette égalité en θ :

$$\boxed{\hat{\theta}_{\text{MM}} = 2\overline{X}_n.}$$

1.5.2 2. Estimateur du maximum de vraisemblance

Question — Question Montrer que l'estimateur du maximum de vraisemblance existe, est unique, et le calculer.

La densité d'une observation est

$$f_{\theta}(x) = \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x).$$

Donc la vraisemblance de l'échantillon est

$$L(\theta) = \theta^{-n} \mathbf{1}_{\{\theta \geq M_n\}}.$$

Si $\theta < M_n$, la vraisemblance est nulle : un tel paramètre ne peut pas avoir produit la plus grande observation. Sur $[M_n, +\infty)$, la fonction $\theta \mapsto \theta^{-n}$ est strictement décroissante. Son maximum unique est donc atteint au plus petit paramètre admissible :

$$\boxed{\hat{\theta}_{\text{MV}} = M_n.}$$

Intuition — Le maximum de vraisemblance choisit exactement la plus petite borne supérieure compatible avec toutes les données. Toute borne plus grande dilue inutilement la densité uniforme.

1.5.3 3. Loi, biais et variance de l'estimateur du maximum

Question — Question Montrer que $\hat{\theta}_{\text{MV}}/\theta \sim \text{Beta}(n, 1)$, puis en déduire son biais et sa variance.

Pour $x \in [0, 1]$,

$$\begin{aligned} \mathbb{P}\left(\frac{M_n}{\theta} \leq x\right) &= \mathbb{P}(X_1 \leq \theta x, \dots, X_n \leq \theta x) \\ &= x^n. \end{aligned}$$

La densité correspondante est $nx^{n-1} \mathbf{1}_{[0,1]}(x)$: c'est bien une loi $\text{Beta}(n, 1)$. Ses moments donnent

$$\mathbb{E}[M_n] = \frac{n}{n+1}\theta, \quad \text{Var}(M_n) = \frac{n}{(n+1)^2(n+2)}\theta^2.$$

Ainsi,

$$\text{Biais}(\hat{\theta}_{\text{MV}}) = -\frac{\theta}{n+1}.$$

L'estimateur sous-estime donc systématiquement θ , ce qui est naturel : le maximum observé reste inférieur à la borne réelle avec probabilité 1 pour un échantillon fini.

1.5.4 4. Biais, variance et comparaison des risques quadratiques

Question — Question Calculer le biais et la variance de $\hat{\theta}_{\text{MM}}$. Comparer les erreurs quadratiques moyennes des deux estimateurs.

Comme $\mathbb{E}[X_i] = \theta/2$ et $\text{Var}(X_i) = \theta^2/12$,

$$\mathbb{E}[\hat{\theta}_{\text{MM}}] = \theta, \quad \text{Var}(\hat{\theta}_{\text{MM}}) = 4 \text{Var}(\bar{X}_n) = \frac{\theta^2}{3n}.$$

L'estimateur des moments est donc sans biais, et

$$\text{MSE}(\hat{\theta}_{\text{MM}}) = \frac{\theta^2}{3n}.$$

Pour le maximum de vraisemblance, on utilise $\text{MSE} = \text{Var} + \text{Biais}^2$:

$$\text{MSE}(\hat{\theta}_{\text{MV}}) = \frac{2\theta^2}{(n+1)(n+2)}.$$

Les deux MSE sont égales pour $n = 1$ et $n = 2$. À partir de $n = 3$,

$$\text{MSE}(\hat{\theta}_{\text{MV}}) < \text{MSE}(\hat{\theta}_{\text{MM}}).$$

Le maximum, bien que biaisé, devient préférable parce que son erreur décroît en ordre $1/n^2$, contre $1/n$ pour l'estimateur des moments.

1.5.5 5. Corriger le biais du maximum

Question — Question Construire un estimateur sans biais à partir de $\hat{\theta}_{\text{MV}}$. Calculer sa MSE et la comparer à celle de $\hat{\theta}_{\text{MM}}$.

Puisque $\mathbb{E}[M_n] = \frac{n}{n+1}\theta$, il suffit de corriger ce facteur :

$$\tilde{\theta} = \frac{n+1}{n} M_n.$$

Alors $\mathbb{E}[\tilde{\theta}] = \theta$. L'estimateur étant sans biais, sa MSE est sa variance :

$$\text{MSE}(\tilde{\theta}) = \text{Var}(\tilde{\theta}) = \frac{\theta^2}{n(n+2)}.$$

Pour $n > 1$,

$$\frac{\theta^2}{n(n+2)} < \frac{\theta^2}{3n} = \text{MSE}(\hat{\theta}_{\text{MM}}).$$

La correction du biais conserve donc l'avantage du maximum sur la méthode des moments, sauf au cas limite $n = 1$ où les deux coïncident.

1.5.6 6. Comportement asymptotique non standard

Question — Question Montrer que $n(1 - \hat{\theta}_{\text{MV}}/\theta)$ converge en loi vers $\mathcal{E}(1)$. Quelle hypothèse usuelle de régularité du MLE échoue ici ?

Pour $x \geq 0$,

$$\begin{aligned} \mathbb{P}\left(n\left(1 - \frac{M_n}{\theta}\right) > x\right) &= \mathbb{P}\left(\frac{M_n}{\theta} < 1 - \frac{x}{n}\right) \\ &= \left(1 - \frac{x}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-x}. \end{aligned}$$

La limite est la fonction de survie d'une loi exponentielle de paramètre 1. Donc

$$n\left(1 - \frac{\hat{\theta}_{\text{MV}}}{\theta}\right) \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{E}(1).$$

L'hypothèse de régularité qui échoue est celle d'un **support fixe** : ici,

$$\text{Supp}(X_i) = [0, \theta]$$

dépend du paramètre. Cette dépendance explique la vitesse en n , plutôt qu'en $\sqrt{n}$, et la limite exponentielle plutôt que normale.

1.6 Exercice 5 - Estimateurs du maximum de vraisemblance

On considère d'abord $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Ber}(p)$, avec $p \in [0, 1]$, et on note $S = \sum_{i=1}^n X_i$.

1.6.1 1(a). MLE du paramètre de Bernoulli

Question — Question Calculer le MLE $\hat{p}_{\text{MV}}$, y compris lorsque toutes les observations valent 0 ou toutes valent 1.

La vraisemblance s'écrit

$$L(p) = \prod_{i=1}^n p^{X_i} (1-p)^{1-X_i} = p^S (1-p)^{n-S}.$$

Lorsque $0 < S < n$, on maximise la log-vraisemblance

$$\ell(p) = S \log p + (n - S) \log(1 - p).$$

Son équation $\ell'(p) = 0$ donne $S(1-p) = p(n-S)$, d'où

$$\hat{p}_{\text{MV}} = \frac{S}{n} = \bar{X}_n.$$

La même formule couvre les cas limites :

$$S = 0 \Rightarrow \hat{p}_{\text{MV}} = 0, \quad S = n \Rightarrow \hat{p}_{\text{MV}} = 1.$$

La fréquence observée de succès est donc le MLE de la probabilité de succès.

1.6.2 1(b). Information de Fisher

Question — Question En supposant $p \in (0, 1)$, calculer l'information de Fisher pour une observation puis pour l'échantillon.

Le score d'une observation est

$$\frac{\partial}{\partial p} \log f_p(X_1) = \frac{X_1 - p}{p(1-p)}.$$

Son carré moyen vaut

$$\begin{aligned} I_{X_1}(p) &= \mathbb{E} \left[\left(\frac{X_1 - p}{p(1-p)} \right)^2 \right] \\ &= \frac{\text{Var}(X_1)}{p^2(1-p)^2} \\ &= \frac{1}{p(1-p)}. \end{aligned}$$

L'information s'additionne pour des observations indépendantes :

$$I_n(p) = \frac{n}{p(1-p)}.$$

1.6.3 1(c). Loi asymptotique et borne de Cramér-Rao

Question — Question Calculer la loi asymptotique de $\sqrt{n}(\hat{p}_{\text{MV}} - p)$ et comparer sa variance asymptotique à la borne de Cramér-Rao.

Comme $\hat{p}_{\text{MV}} = \bar{X}_n$ et $\text{Var}(X_i) = p(1-p)$, le théorème central limite donne

$$\sqrt{n}(\hat{p}_{\text{MV}} - p) \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, p(1-p)).$$

Ainsi, la variance de l'estimateur est asymptotiquement $p(1-p)/n$. Or l'inverse de l'information de Fisher de l'échantillon est

$$\frac{1}{I_n(p)} = \frac{p(1-p)}{n}.$$

La variance asymptotique atteint donc la borne de Cramér-Rao : la fréquence empirique est asymptotiquement efficace.